

1 优化目标

考虑如下 group LASS 问题：

$$\min_{x \in \mathbb{R}^{n \times l}} \frac{1}{2} \|Ax - b\|_F^2 + \mu \|x\|_{1,2}$$

其中 $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^{m \times l}$, 给定 $\mu > 0$, $\|x\|_{1,2}$ 由如下给出：

$$\|x\|_{1,2} = \sum_{i=1}^n \|x(i, 1:l)\|_2.$$

2 cvx 求解

利用 python 中的 cvxpy 包，如下为调用 mosek 和 gurobi 求解器得到的解，其中解为 $n \times l$ 矩阵，按列将解画在图上：




图 1: CVX-Mosek 解与精确解 u 对比

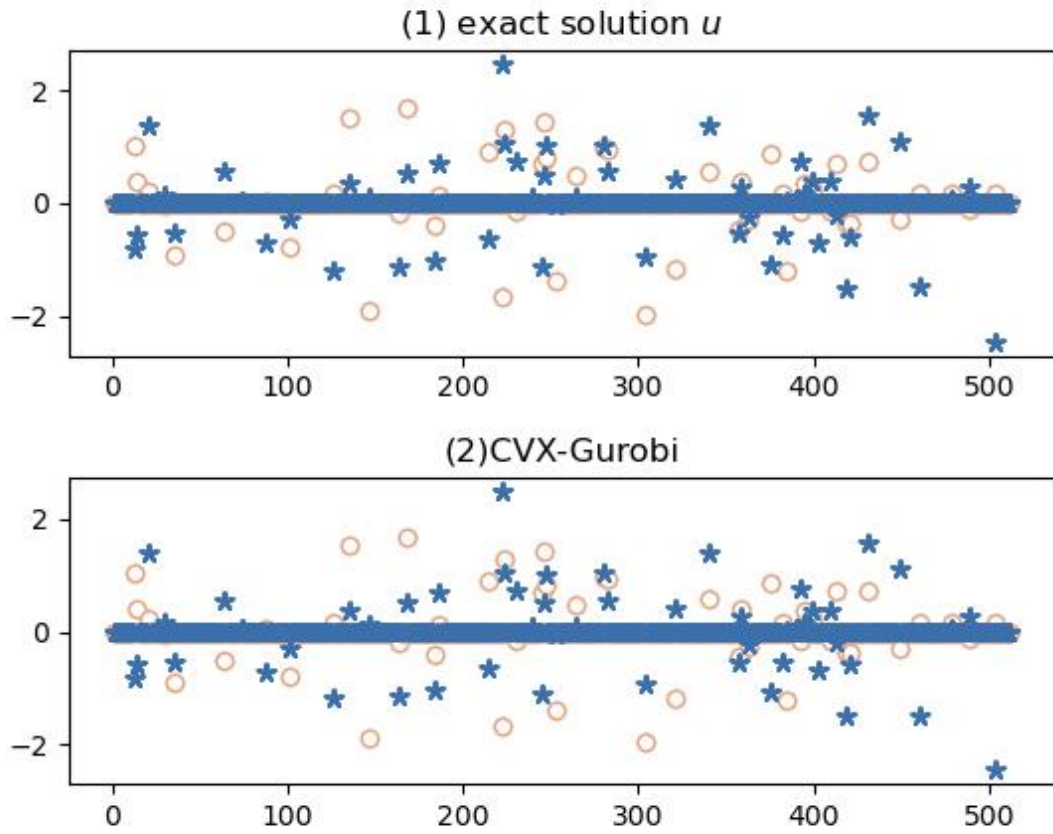


图 2: CVX-Gurobi 得到的解与精确解 u 对比

3 mosek 求解器和 gurobi 求解器

在调用 mosek 和 gurobi 前，现将原问题转化为如下等价的二次规划和二次锥约束问题：

$$\begin{aligned} \min_{x,t} \quad & \frac{1}{2} \|Ax - b\|_F^2 + \mu \mathbf{1}t \\ \text{s.t.} \quad & \|x(i, 1:l)\| \leq t_i, i = 1, 2, \dots, n \end{aligned}$$

其中向量 $\mathbf{1} \in \mathcal{R}^n$ ，下面展示了具体结果：

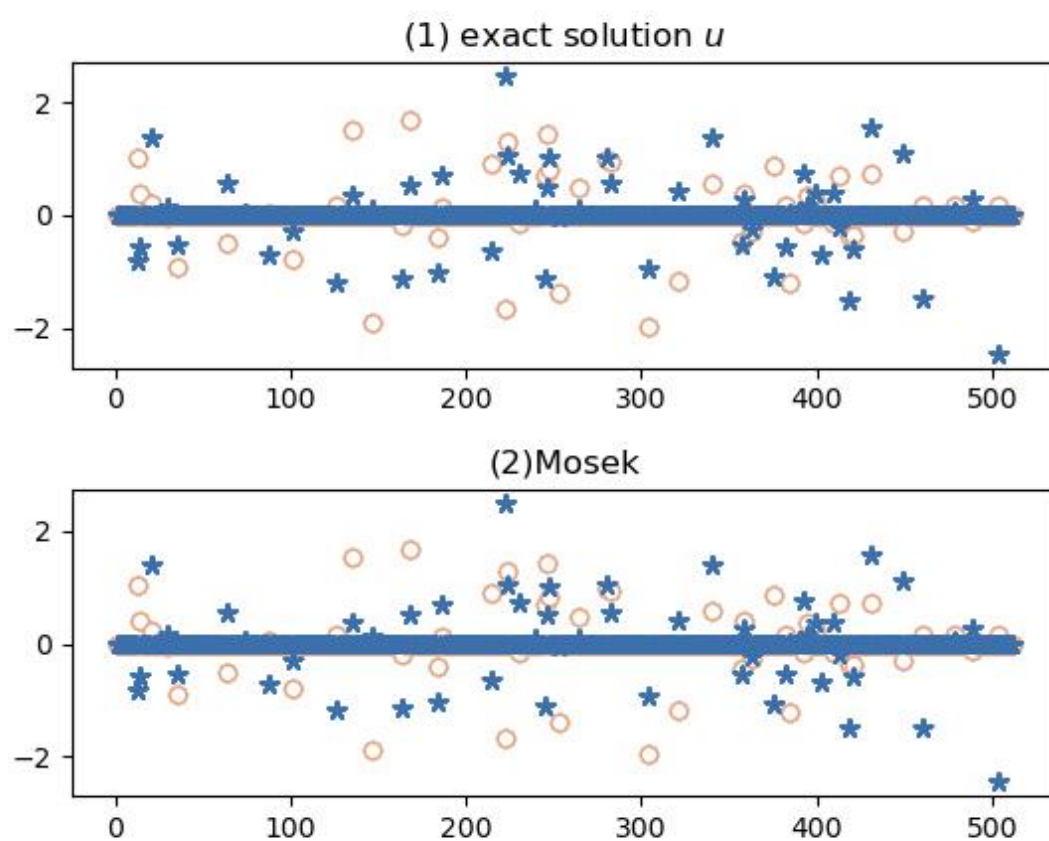


图 3: Mosek 得到的解与精确解 u 对比




图 4: Gurobi 得到的解与精确解 u 对比

4 次梯度法

对于函数 $f(x) = \frac{1}{2}\|Ax - b\|_F^2 + \mu\|x\|_{1,2}$, 它的次梯度可以表示如下

$$\partial f(x) = A^T Ax - A^T b + \mu \partial \|x\|_{1,2}$$

其中

$$\partial \|x\|_{1,2} = \begin{bmatrix} \partial x(1, 1:l) \\ \partial x(2, 1:l) \\ \vdots \\ \partial x(n, 1:l) \end{bmatrix}$$

$$\partial x(i, 1:l) = \begin{cases} \frac{x(i, 1:l)}{\|x(i, 1:l)\|_2}, & x(i, 1:l) \neq \mathbf{0} \\ \{w \mid \|w\|_2 \leq 1\}, & x(i, 1:l) = \mathbf{0} \end{cases}$$

利用辅助函数确定当前步长, 然后进行一步次梯度法迭代 $x^{k+1} = x^k - \alpha_k g(x^k)$ 。其中 $g(x^k) \in \partial f(x^k)$ 。题目中 μ 的值过小, 直接求解收敛速度过慢, 所以先从较大的 μ 开始, 采用连续化策略, 直到 μ 衰减到题目中要求的值。




图 5: SGD 得到的解与精确解 u 对比

5 近似点梯度法

优化问题可以看作 $f(x) = \phi(x) + h(x)$, 其中 $\phi(x) = \frac{1}{2}\|Ax - b\|_F^2$, $h(x) = \mu\|x\|_{1,2}$. 题目中 μ 的值过小, 直接求解收敛速度过慢, 采用连续化策略, 连续化策略从较大的正则化参数 μ_t 逐渐减小到 μ (即 $\mu_1 \geq \dots \geq \mu_{t-1} \geq \mu_t \geq \dots \geq \mu$), 并求解相应的 LASSO 问题:

事实上, 近似点梯度法的迭代格式根据定义可以写为

$$\begin{aligned} x^{k+1} &= \arg \min_u \left(\mu_k \|u\|_{1,2} + \frac{1}{2\alpha_k} \|u - x^k + \alpha_k \nabla \phi(x^k)\|_2^2 \right) \\ &= \arg \min_u \left(\mu_k \|u\|_{1,2} + \phi(x^k) + \nabla \phi(x^k)^\top (u - x^k) + \frac{1}{2\alpha_k} \|u - x^k\|_2^2 \right). \end{aligned}$$

检验是否满足非精确线搜索条件, 针对 $f(x)$ 考虑线搜索准则, 即为 $f(x^{k+1}(t)) \leq C_k - \frac{1}{2}\rho t \|x^{k+1}(t) - x^k\|^2$, 其中 $x^{k+1}(t) = \text{prox}_{\mu_k \|\cdot\|_{1,2}}(x^k - \alpha_k \nabla \phi(x^k))$ 。

$|\text{nls}|$ 记录线搜索循环的迭代次数, 直到满足条件或进行 10 次步长衰减后退出线搜索循环, 得到更新的 x^{k+1} 。 C_k 为 (Zhang & Hager) 线搜索准则中的量。 如果不满足线搜索条件, 对当前步长进行衰减, 当前线搜索次数加一。 线搜索结束, 得到更新的 x, g 。 计算梯度范数和原始目标函数值。 fvec 记录每一步对应的原 LASSO 问题的目标函数值。 并进行内层循环的收敛判断: 若当前梯度小于阈值或者目标函数变化小于阈值, 内层迭代终止。

计算 BB 步长作为下一步迭代的初始步长。 令 $s^k = x^{k+1} - x^k, y^k = g^{k+1} - g^k$, 这里在偶数与奇数步分别对应 $\frac{(s^k)' s^k}{(s^k)^\top y^k}$ 和 $\frac{(s^k)^\top y^k}{(y^k)^\top y^k}$ 两个 BB 步长。

得到如下结果:




图 6: ProxGD 得到的解与精确解 u 对比

6 FProxGD 算法

利用 Nesterov 加速的近似点梯度法进行优化。该算法被外层连续化策略调用，在连续化策略下完成某一固定正则化系数的内层迭代优化。在每一步迭代时，算法首先在之前两步迭代点的基础上进行一步更新 $y^k = x^{k-1} + \frac{k-2}{k+1}(x^{k-1} - x^{k-2})$ ，然后再在 y^k 处进行一步近似点梯度法， $x^k = \text{prox}_{\mu_k \|\cdot\|_{1,2}}(y^k - t_k A^\top (A y^k - b))$ 。




图 7: FProxGD 得到的解与精确解 u 对比

7 对偶问题的 ALM 算法

原问题等价于

$$\begin{aligned} \min_{x,z} & \frac{1}{2} \|z - b\|_F^2 + \mu \|x\|_{1,2} \\ \text{s.t.} & Ax - z = 0 \end{aligned}$$

构造拉格朗日函数 $L(x, z, y) = \frac{1}{2} \|y - b\|_F^2 - \langle z, y \rangle + \mu \|x\|_{1,2} + \langle A^T y, x \rangle$ 通过最小化 x 和

z , 我们有:

$$\begin{aligned} g(y) &= \inf_{x,z} L(x, z, y) = \inf_{x,z} \frac{1}{2} \|y - b\|_F^2 - \langle z, y \rangle + \mu \|x\|_{1,2} + \langle A^T y, x \rangle \\ &= -\frac{1}{2} \|y\|_F^2 - \langle b, y \rangle + I \left[\|A^T y\|_{\infty,2}^* \leq \mu \right] \end{aligned}$$

因此原问题的对偶问题为:

$$\begin{aligned} \min_y \quad & \frac{1}{2} \|y\|_F^2 + \langle b, y \rangle \\ \text{s.t.} \quad & \|A^T y\|_{\infty,2} \leq \mu. \end{aligned}$$

其中矩阵的 $(\infty, 2)$ 范数定义为 $\|A\|_{\infty,2} = \max_i \|A(i, 1:l)\|_2$, 为了避免复杂的符号 $\|A^T z\|_{\infty,2}$, 引入等式约束, 使得 ALM 算法更加的平滑。

$$\begin{aligned} \min_y \quad & \frac{1}{2} \|y\|_F^2 + \langle b, y \rangle \\ \text{s.t.} \quad & \|s\|_{\infty,2} \leq \mu, s = A^T y \end{aligned}$$

它的增广拉格朗日函数为:

$$L^d(y, s, \lambda, \mu) = \frac{1}{2} \|y\|_F^2 + \langle b, y \rangle + \langle \lambda, A^T y - s \rangle + \frac{\sigma}{2} \|A^T y - s\|_F^2$$

以及约束 $\|s\|_{\infty,2} \leq \mu$ 。因此对偶问题的增广拉格朗日函数法对于每个固定的 λ 解决如下子问题:

$$\begin{aligned} \min_{y,s} \quad & \frac{1}{2} \|y\|_F^2 + \langle b, y \rangle + \langle \lambda, A^T y - s \rangle + \frac{\sigma}{2} \|A^T y - s\|_F^2 \\ \text{s.t.} \quad & \|s\|_{\infty,2} \leq \mu \end{aligned}$$

7.1 迭代格式

上述对偶问题的增广拉格朗日函数法的迭代格式为

$$\begin{cases} (y^{k+1}, s^{k+1}) = \arg \min_{y, \|s\|_{\infty,2} \leq \mu} L^d(y, s, \lambda^k, \mu) = \arg \min_{y, \|s\|_{\infty,2} \leq \mu} \left\{ \frac{1}{2} \|y\|_F^2 + \langle b, y \rangle + \frac{\sigma_k}{2} \|A^T y - s + \frac{\lambda}{\sigma_k}\|_F^2 \right\} \\ \lambda^{k+1} = \lambda^k + \sigma_k (A^T y^{k+1} - s^{k+1}) \\ \sigma_{k+1} = \min \{ \rho \sigma_k, \bar{\sigma} \} \end{cases}$$

其中 $\rho > 1$ 和 $\bar{\sigma} < +\infty$ 为算法参数, 由于 (y^{k+1}, s^{k+1}) 的显式表达式是未知的, 我们需要利用迭代算法来进行求解。

首先关于 y 的极小化问题为:

$$\min \frac{1}{2} \|y\|_F^2 + \langle b, y \rangle + \langle \lambda, A^T y - s \rangle + \frac{\sigma}{2} \|A^T y - s\|_F^2$$

进一步化简可知:

$$y = \arg \min_y \text{tr} \left(\frac{1}{2} \|y\|_F^2 + \frac{1}{2} y^\top (\sigma_k A A^\top) y + (b^\top + \lambda^\top A^\top - \sigma_k s^\top A^\top) y \right)$$

设 $h(y) = \frac{1}{2} (\sigma_k A A^\top) y + (b^\top + \lambda^\top A^\top - \sigma_k s^\top A^\top) y$, 那么 $y = \text{prox}_h(0) = \arg \min_u \{h(u) + \frac{1}{2} \|y\|_F^2\}$,

有二次函数的近似算法可知 $y = (I + \sigma_k A A^\top)^{-1} (\sigma_k A s - A \lambda - b)$

关于 s 的极小化问题为:

$$\begin{aligned} \min_s \quad & \frac{\sigma_k}{2} \left\| A^T y - s + \frac{\lambda}{\sigma_k} \right\|_F^2 \\ \text{s.t.} \quad & \|s\|_{\infty, 2} \leq \mu \end{aligned}$$

通过简单的推导可知:

$$s = \mathcal{P}_{\|s\|_{\infty, 2} \leq \mu} \left(A^T y + \frac{\lambda}{\sigma_k} \right)$$

7.2 优化结果




图 8: ALM Dual 得到的解与精确解 u 对比

8 对偶问题的 ADMM 算法




图 9: ADMM Dual 得到的解与精确解 u 对比

9 原问题的 ADMM 算法

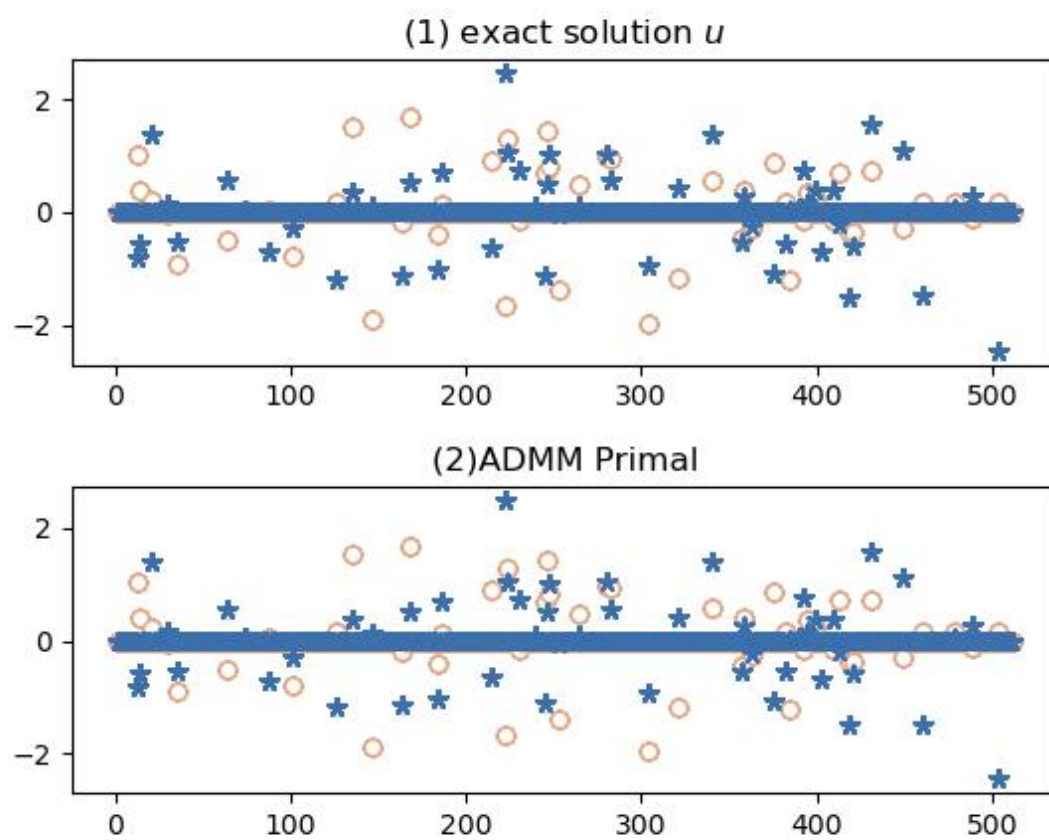


图 10: ADMM Primal 得到的解与精确解 u 对比

10 总结

表 1: 比较不同算法的效率

Solver	Time(s)	Iter	Fval	Sparisity	Errfun-Exact	Errfun-CVX-Mosek	Errfun-CVX-Gurobi
CVX-Mosek	0.46	9	5.42980E-01	0.294	4.21E-05	0.00E+00	1.47E-06
CVX-Gurobi	3.86	16	5.42980E-01	0.328	4.33E-05	1.47E-06	0.00E+00
Mosek	0.25	10	5.42980E-01	0.291	4.19E-05	2.94E-07	1.72E-06
Gurobi	4.20	14	5.42986E-01	0.750	4.72E-05	6.43E-06	5.14E-06
SGD Primal	19.12	100	5.42983E-01	0.578	5.79E-05	1.90E-05	1.79E-05
ProxGD Primal	22.34	13	5.42980E-01	0.291	4.19E-05	3.11E-07	1.73E-06
FProxGD Primal	4.99	6	5.42980E-01	0.291	4.19E-05	3.19E-07	1.74E-06
ALM Dual	1.54	283	5.42997E-01	0.248	7.59E-05	4.33E-05	4.26E-05
ADMM Dual	0.69	76	5.42998E-01	0.248	8.07E-05	4.67E-05	4.59E-05
ADMM Primal	9.52	2392	5.42980E-01	0.291	4.19E-05	3.21E-07	1.71E-06